

HỌC MÁY CƠ BẢN VỚI PYTHON

Chương 3 – Buổi 1

Vector, ma trận và thống kê mô tả

(Vectors, Matrices & Descriptive Statistics)

Lê Nhật Tùng

Bài giảng đi kèm giáo trình

Mục tiêu buổi học

Sau buổi học này, bạn có thể:

- Hiểu **vector** (*vector*) và **ma trận** (*matrix*) như những "bảng số"; tính **khoảng cách** (*distance*), **tích vô hướng** (*dot product*), nhân ma trận với vector.
- Giải thích vì sao **thang đo** (*scale*) của các cột làm thay đổi khoảng cách.
- Tính và diễn giải **trung bình** (*mean*), **trung vị** (*median*), **độ lệch chuẩn** (*standard deviation*), **phân vị** (*percentile*), **hệ số tương quan** (*correlation coefficient*).
- Kiểm tra mọi phép tính tay bằng vài dòng NumPy.

Nội dung

1. Vector (*Vectors*)

2. Ma trận

3. Thống kê mô tả

4. Thực hành Buổi 3.1

5. Tổng kết Buổi 3.1

Vì sao cần toán, và cần đến đâu?

Mảng toán	**Trả lời câu hỏi**	**Dùng ở đâu**
Vector, ma trận *(linear algebra)*	Biểu diễn dữ liệu thế nào? Hai mẫu giống nhau đến đâu?	Mọi chương; kNN, phân cụm, PCA
Đạo hàm, gradient *(calculus)*	Mô hình "học" bằng cách nào?	Hồi quy, mạng nơ-ron
Thống kê mô tả *(statistics)*	Dữ liệu trông ra sao? Có bất thường không?	Khám phá, tiền xử lý dữ liệu
Xác suất *(probability)*	Mô hình chắc chắn đến đâu?	Phân loại, Naive Bayes, đánh giá

Nhịp học của mỗi phần: **trực giác** → **công thức** → **tính tay** → **kiểm tra bằng Python**.

Hai buổi – hai câu hỏi lớn

Buổi 3.1 (hôm nay)

Dữ liệu được biểu diễn và mô tả thế nào?

- Vector, khoảng cách, tích vô hướng
- Ma trận, nhân ma trận với vector
- Thống kê mô tả

Buổi 3.2

Máy học bằng cách nào và chắc chắn đến đâu?

- Đạo hàm, gradient descent
- "Huấn luyện" một mô hình bằng tay
- Xác suất, định lý Bayes, phân phối chuẩn

Nhịp của mỗi mục: **trực giác** → **công thức** → **ví dụ tính tay** → **kiểm tra bằng Python**. Hãy cầm bút và tự tính!

Ký hiệu tổng $\sum$ – đọc công thức thành câu

Toán dễ hiểu: Ký hiệu tổng – summation

Chữ $\sum$ (đọc "xích-ma", *sigma*) nghĩa là **cộng dồn**:

$$\sum_{i=1}^{n} x_i = x_1 + x_2 + \cdots + x_n$$

- Đọc thành câu: "cộng tất cả các x_i, với i chạy từ 1 đến n".
- Ví dụ $x = (2, 5, 3)$: $\sum_{i=1}^{3} x_i = 2 + 5 + 3 = 10$ và $\sum_{i=1}^{3} x_i^2 = 4 + 25 + 9 = 38$.
- Trong NumPy: $\sum_i x_i$ chính là `np.sum(x)`; $\sum_i x_i^2$ là `np.sum(x ** 2)`.

Mẹo nhỏ

Khi gặp một công thức nhiều ký hiệu, hãy **đọc nó thành câu tiếng Việt**. Công thức chỉ là cách viết tắt của một câu nói.

Bài tập mẫu: đọc và tính biểu thức tổng

Với $x = (1, 3, 4)$ và $y = (2, 0, 5)$, tính $\sum_{i=1}^{3} x_i y_i$ và $\sum_{i=1}^{3} (x_i - 2)^2$.

Bài tập mẫu

Lời giải.

- "Cộng các tích $x_i y_i$ với i từ 1 đến 3": $1 \times 2 + 3 \times 0 + 4 \times 5 = 2 + 0 + 20 = \mathbf{22}$.
- "Lấy từng x_i trừ 2, bình phương, rồi cộng": $(1-2)^2 + (3-2)^2 + (4-2)^2 = 1 + 1 + 4 = \mathbf{6}$.

Trong NumPy: `np.sum(x * y)` và `np.sum((x - 2) ** 2)`. Hai dạng biểu thức này chính là **tích vô hướng** và **phương sai** sắp học.

Phần 1

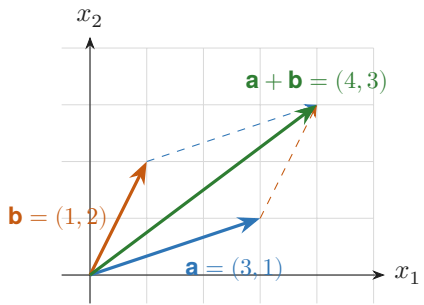
Vector (*Vectors*)

Vector: mỗi mẫu dữ liệu là một vector

Định nghĩa: Vector

Một dãy số có thứ tự, ví dụ $\mathbf{a} = (3, 1)$. Số phần tử gọi là **số chiều** (*dimension*). Vector d chiều: $\mathbf{a} = (a_1, \ldots, a_d) \in \mathbb{R}^d$ (đọc "thuộc R mũ d").

- Bông hoa Iris: vector 4 chiều $(5{,}1;\ 3{,}5;\ 1{,}4;\ 0{,}2)$.
- Căn nhà (diện tích, số phòng): vector 2 chiều.
- Vector 2 chiều vẽ được như **mũi tên** hoặc **một điểm**.



Ví dụ đời thường: hồ sơ sức khỏe là một vector

Ví dụ đời thường: Thứ tự rất quan trọng

Phiếu khám: chiều cao 168 cm, cân nặng 60 kg, nhịp tim 72 lần/phút. Viết gọn theo **đúng thứ tự đã quy ước**: $(168, 60, 72)$ – một vector 3 chiều. Còn $(60, 168, 72)$ là một người khác hẳn (cao 60 cm, nặng 168 kg!).

Bài tập mẫu: Phép toán vector: $\mathbf{u} = (2, -1, 4)$, $\mathbf{v} = (1, 3, 0)$

Lời giải.

- $\mathbf{u} + \mathbf{v} = (3, 2, 4)$; $\quad \mathbf{u} - 2\mathbf{v} = (2-2,\ -1-6,\ 4-0) = (0, -7, 4)$.
- $\|\mathbf{u}\| = \sqrt{2^2 + (-1)^2 + 4^2} = \sqrt{21} \approx 4{,}583$ (chú ý $(-1)^2 = 1$).

Phép toán cơ bản và độ dài vector

Toán dễ hiểu: Cộng, nhân với một số

Thực hiện **theo từng thành phần**. Với $\mathbf{a} = (3, 1)$, $\mathbf{b} = (1, 2)$:

$$\mathbf{a} + \mathbf{b} = (4, 3), \qquad 2\mathbf{a} = (6, 2)$$

$$\mathbf{a} - \mathbf{b} = (2, -1)$$

Phép toán cơ bản và độ dài vector

Toán dễ hiểu: Cộng, nhân với một số

Thực hiện **theo từng thành phần**. Với $\mathbf{a} = (3, 1)$, $\mathbf{b} = (1, 2)$:

$$\mathbf{a} + \mathbf{b} = (4, 3), \qquad 2\mathbf{a} = (6, 2)$$

$$\mathbf{a} - \mathbf{b} = (2, -1)$$

Toán dễ hiểu: Độ dài – chuẩn (norm)

Theo định lý Pythagoras:

$$\|\mathbf{a}\| = \sqrt{a_1^2 + \cdots + a_d^2}$$

$$\|(3, 1)\| = \sqrt{3^2 + 1^2} = \sqrt{10} \approx 3{,}1623$$

ch03.py — ô vec_co_ban

```python
a = np.array([3, 1])
b = np.array([1, 2])
print("a + b   =", a + b)
print("2 * a   =", 2 * a)
print("a - b   =", a - b)
print("||a||   =", np.sqrt(np.sum(a ** 2)))  # độ dài theo công thức
print("||a||   =", np.linalg.norm(a))  # hàm có sẵn của NumPy
```

Kết quả

```
a + b   = [4 3]
2 * a   = [6 2]
a - b   = [ 2 -1]
||a||   = 3.1622776601683795
||a||   = 3.1622776601683795
```

Khoảng cách Euclid: hai mẫu giống nhau đến đâu?

Toán dễ hiểu: Khoảng cách Euclid – Euclidean distance

$$d(\mathbf{p}, \mathbf{q}) = \sqrt{(p_1 - q_1)^2 + \cdots + (p_d - q_d)^2}$$

4 bước: **(1)** trừ từng thành phần **(2)** bình phương **(3)** cộng lại **(4)** lấy căn.

Khoảng cách Euclid: hai mẫu giống nhau đến đâu?

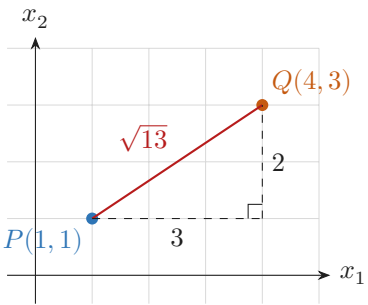
Toán dễ hiểu: Khoảng cách Euclid – Euclidean distance

$$d(\mathbf{p}, \mathbf{q}) = \sqrt{(p_1 - q_1)^2 + \cdots + (p_d - q_d)^2}$$

4 bước: **(1)** trừ từng thành phần **(2)** bình phương **(3)** cộng lại **(4)** lấy căn.

$$d(P, Q) = \sqrt{(1-4)^2 + (1-3)^2} = \sqrt{13} \approx 3{,}606$$

Đây là khái niệm quan trọng bậc nhất: hai mẫu **giống nhau** (*similar*) khi khoảng cách **nhỏ** – chính là cách kNN (Chương 1) tìm hàng xóm. Công thức dùng được cho **mọi số chiều**, kể cả khi không vẽ được hình.



Ví dụ: khoảng cách giữa hai bông hoa Iris (4 chiều)

	Dài đài	Rộng đài	Dài cánh	Rộng cánh
Hoa 1 (*setosa*)	5,1	3,5	1,4	0,2
Hoa 51 (*versicolor*)	7,0	3,2	4,7	1,4

Ví dụ: khoảng cách giữa hai bông hoa Iris (4 chiều)

	Dài đài	Rộng đài	Dài cánh	Rộng cánh
Hoa 1 (*setosa*)	5,1	3,5	1,4	0,2
Hoa 51 (*versicolor*)	7,0	3,2	4,7	1,4
(1) Hiệu	$-1{,}9$	$0{,}3$	$-3{,}3$	$-1{,}2$

Ví dụ: khoảng cách giữa hai bông hoa Iris (4 chiều)

	Dài đài	Rộng đài	Dài cánh	Rộng cánh
Hoa 1 (*setosa*)	5,1	3,5	1,4	0,2
Hoa 51 (*versicolor*)	7,0	3,2	4,7	1,4
(1) Hiệu	$-1{,}9$	$0{,}3$	$-3{,}3$	$-1{,}2$
(2) Bình phương	3,61	0,09	**10,89**	1,44

Ví dụ: khoảng cách giữa hai bông hoa Iris (4 chiều)

	Dài đài	Rộng đài	Dài cánh	Rộng cánh
Hoa 1 (*setosa*)	5,1	3,5	1,4	0,2
Hoa 51 (*versicolor*)	7,0	3,2	4,7	1,4
(1) Hiệu	$-1{,}9$	$0{,}3$	$-3{,}3$	$-1{,}2$
(2) Bình phương	3,61	0,09	**10,89**	1,44

(3) Tổng: $3{,}61 + 0{,}09 + 10{,}89 + 1{,}44 = 16{,}03$ (4) $\sqrt{16{,}03} \approx$ **4,0037**

Lưu ý

Cột có chênh lệch lớn (*dài cánh*: 10,89) **lấn át** các cột khác. Nếu một cột đo bằng mét, cột kia đo bằng milimét, khoảng cách gần như chỉ do cột milimét quyết định $\Rightarrow$ cần **chuẩn hóa** (Chương 4).

Kiểm tra bằng NumPy

ch03.py — ô vec_khoang_cach

```
hoa_1 = np.array([5.1, 3.5, 1.4, 0.2])     # bông hoa số 1 của Iris (setosa)
hoa_2 = np.array([7.0, 3.2, 4.7, 1.4])     # bông hoa số 51 (versicolor)
hieu = hoa_1 - hoa_2
print("Hiệu từng thành phần :", hieu.round(2))
print("Bình phương          :", (hieu ** 2).round(2))
print("Tổng bình phương     :", round(np.sum(hieu ** 2), 2))
print("Khoảng cách Euclid   :", round(np.sqrt(np.sum(hieu ** 2)), 4))
print("Dùng np.linalg.norm  :", round(np.linalg.norm(hoa_1 - hoa_2), 4))
```

Kết quả

```
Hiệu từng thành phần : [-1.9  0.3 -3.3 -1.2]
Bình phương          : [ 3.61  0.09 10.89  1.44]
Tổng bình phương     : 16.03
Khoảng cách Euclid   : 4.0037
Dùng np.linalg.norm  : 4.0037
```

- Kết quả khớp với tính tay: $\sqrt{16{,}03} \approx 4{,}0037$.
- `np.linalg.norm(p - q)`: độ dài của vector hiệu = khoảng cách. `linalg` là viết tắt của *linear algebra* (đại số tuyến tính).
- Chênh lệch chiều dài cánh hoa đóng góp nhiều nhất – khớp với biểu đồ phân tán ở Chương 1: cánh hoa phân biệt các loài rõ nhất.

Bài tập mẫu: căn nhà nào giống căn A nhất?

Ba căn nhà (diện tích m², số phòng ngủ): A $= (60, 2)$, B $= (62, 4)$, C $= (70, 2)$.

Đơn vị m²

$d(A, B) = \sqrt{2^2 + 2^2} \approx 2{,}828$
$d(A, C) = \sqrt{10^2 + 0^2} = 10$
$\Rightarrow$ **B** gần A hơn.

Đơn vị chục m²

A $= (6, 2)$, B $= (6{,}2;\ 4)$, C $= (7, 2)$
$d(A, B) = \sqrt{0{,}04 + 4} \approx 2{,}01;\ \ d(A, C) = 1$
$\Rightarrow$ **C** gần A hơn!

Lưu ý

Ba căn nhà không đổi, chỉ **đơn vị đo** đổi, mà kết luận "căn nào giống nhất" bị **đảo ngược**. Đây là lý do phải **chuẩn hóa** *(scaling)* dữ liệu (Chương 4) – và lý do kNN làm kém trên Wine (cột `proline` hàng nghìn).

Kiểm tra bằng NumPy: thang đo đảo ngược kết luận

ch03.py — ô vec_thang_do

```
# Ba căn nhà: (diện tích m², số phòng ngủ). Căn nào giống căn A nhất?
A = np.array([60, 2])
B = np.array([62, 4])      # gần như cùng diện tích, nhưng nhiều hơn 2 phòng
C = np.array([70, 2])      # cùng số phòng, rộng hơn 10 m²
print("d(A, B) =", round(np.linalg.norm(A - B), 3))
print("d(A, C) =", round(np.linalg.norm(A - C), 3))
# Đổi diện tích sang đơn vị "chục m²": chỉ đổi đơn vị, căn nhà không đổi!
A2, B2, C2 = np.array([6.0, 2]), np.array([6.2, 4]), np.array([7.0, 2])
print("Sau khi đổi đơn vị: d(A, B) =", round(np.linalg.norm(A2 - B2), 3),
      "  d(A, C) =", round(np.linalg.norm(A2 - C2), 3))
```

Kết quả

```
d(A, B) = 2.828
d(A, C) = 10.0
Sau khi đổi đơn vị: d(A, B) = 2.01   d(A, C) = 1.0
```

Tích vô hướng (dot product)

Toán dễ hiểu: Tích vô hướng – dot product

$$\mathbf{a} \cdot \mathbf{b} = a_1 b_1 + \cdots + a_d b_d = \sum_{j=1}^{d} a_j b_j$$

Kết quả là **một con số**.

Ví dụ: Giỏ hàng

Mua 2 bút, 3 vở, 1 thước; đơn giá 5, 12, 8 nghìn:

$$(2, 3, 1) \cdot (5, 12, 8) = 10 + 36 + 8 = 54.$$

ch03.py — ô vec_dot

```
so_luong = np.array([2, 3, 1])          # 2 bút, 3 vở, 1 thước
don_gia = np.array([5, 12, 8])          # nghìn đồng
print("Tổng tiền:", np.dot(so_luong, don_gia), "nghìn đồng")
print("Cách viết khác (@):", so_luong @ don_gia)
```

Kết quả

```
Tổng tiền: 54 nghìn đồng
Cách viết khác (@): 54
```

Tích vô hướng (dot product)

Toán dễ hiểu: Tích vô hướng – dot product

$$\mathbf{a} \cdot \mathbf{b} = a_1 b_1 + \cdots + a_d b_d = \sum_{j=1}^{d} a_j b_j$$

Kết quả là **một con số**.

Ví dụ: Giỏ hàng

Mua 2 bút, 3 vở, 1 thước; đơn giá 5, 12, 8 nghìn:

$$(2, 3, 1) \cdot (5, 12, 8) = 10 + 36 + 8 = 54.$$

ch03.py — ô vec_dot

```
so_luong = np.array([2, 3, 1])          # 2 bút, 3 vở, 1 thước
don_gia = np.array([5, 12, 8])          # nghìn đồng
print("Tổng tiền:", np.dot(so_luong, don_gia), "nghìn đồng")
print("Cách viết khác (@):", so_luong @ don_gia)
```

Kết quả

```
Tổng tiền: 54 nghìn đồng
Cách viết khác (@): 54
```

Chương 5: hồi quy tuyến tính dự đoán

$$\hat{y} = w_1 x_1 + \cdots + w_d x_d + b = \mathbf{w} \cdot \mathbf{x} + b$$

w là "đơn giá" – **trọng số** (*weights*) – của từng đặc trưng mà mô hình phải học.

Độ tương đồng cosine (*cosine similarity*): so sánh văn bản

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \, \|\mathbf{b}\|}$$

gần 1: cùng hướng (giống nhau); gần 0: không liên quan

ch03.py — ô vec_cosine

```python
def cosine(u, v):
    return np.dot(u, v) / (np.linalg.norm(u) * np.linalg.norm(v))

# Số lần xuất hiện các từ ["bóng đá", "bàn thắng", "cổ phiếu"] trong 3 bài báo
bai_1 = np.array([5, 3, 0])
bai_2 = np.array([10, 7, 1])
bai_3 = np.array([0, 1, 6])
print("cos(bài 1, bài 2) =", round(cosine(bai_1, bai_2), 4))
print("cos(bài 1, bài 3) =", round(cosine(bai_1, bai_3), 4))
```

Kết quả

```
cos(bài 1, bài 2) = 0.9942
cos(bài 1, bài 3) = 0.0846
```

Mỗi bài báo được biểu diễn bằng số lần xuất hiện của các từ. Bài 1 và bài 2 cùng nói về bóng đá (0,99) dù bài 2 dài gấp đôi; bài 3 về chứng khoán (0,08). Cosine chỉ quan tâm **hướng**, không quan tâm độ dài.

Bài tập mẫu: tính tay độ tương đồng cosine

Bài tập mẫu: Cosine giữa a $= (1, 2)$ và b $= (2, 4)$; giữa a và c $= (2, -1)$

Lời giải.

- $\mathbf{a} \cdot \mathbf{b} = 2 + 8 = 10$; $\|\mathbf{a}\| = \sqrt{5}$, $\|\mathbf{b}\| = \sqrt{20} \Rightarrow \cos = \dfrac{10}{\sqrt{100}} = 1$: **cùng hướng** ($\mathbf{b} = 2\mathbf{a}$) dù dài khác nhau.
- $\mathbf{a} \cdot \mathbf{c} = 2 - 2 = 0 \Rightarrow \cos = 0$: hai vector **vuông góc**.

Tự kiểm tra nhanh

(1) Khoảng cách giữa $(0, 0, 0)$ và $(1, 2, 2)$? (2) $(1, 0, 3) \cdot (2, 5, -1)$? (3) Vì sao cosine giữa hai bài báo không phụ thuộc độ dài bài?

Bài tập mẫu: tính tay độ tương đồng cosine

Bài tập mẫu: Cosine giữa a $= (1, 2)$ và b $= (2, 4)$; giữa a và c $= (2, -1)$

Lời giải.

- $\mathbf{a} \cdot \mathbf{b} = 2 + 8 = 10$; $\|\mathbf{a}\| = \sqrt{5}$, $\|\mathbf{b}\| = \sqrt{20} \Rightarrow \cos = \dfrac{10}{\sqrt{100}} = 1$: **cùng hướng** ($\mathbf{b} = 2\mathbf{a}$) dù dài khác nhau.
- $\mathbf{a} \cdot \mathbf{c} = 2 - 2 = 0 \Rightarrow \cos = 0$: hai vector **vuông góc**.

Tự kiểm tra nhanh

(1) Khoảng cách giữa $(0, 0, 0)$ và $(1, 2, 2)$? (2) $(1, 0, 3) \cdot (2, 5, -1)$? (3) Vì sao cosine giữa hai bài báo không phụ thuộc độ dài bài?

Đáp án: (1) 3. (2) -1. (3) Nhân vector với số dương không đổi hướng; cosine chỉ đo hướng.

Phần 2

Ma trận

Ma trận và phép chuyển vị

Định nghĩa: Ma trận – Matrix

Bảng số m dòng (*rows*), n cột (*columns*) (cỡ $m \times n$); phần tử dòng i, cột j là A_{ij}.

Ma trận đặc trưng X cỡ $n \times d$: mỗi dòng là một mẫu. Ba căn nhà (diện tích, số phòng ngủ):

$$X = \begin{pmatrix} 50 & 2 \\ 80 & 3 \\ 120 & 4 \end{pmatrix}, \qquad X^\top = \begin{pmatrix} 50 & 80 & 120 \\ 2 & 3 & 4 \end{pmatrix}$$

Chuyển vị (*transpose*) $X^\top$: biến dòng thành cột (NumPy: `X.T`).

ch03.py — ô mat_tao

```
1 X = np.array([[50, 2],          # căn nhà 1: 50
    ↪ m², 2 phòng ngủ
2               [80, 3],          # căn nhà 2
3               [120, 4]])        # căn nhà 3
4 print("X =\n", X)
5 print("X.shape   =", X.shape)
6 print("X.T =\n", X.T)            # chuyển vị:
    ↪ dòng thành cột
7 print("X.T.shape =", X.T.shape)
```

Kết quả

```
X =
 [[ 50   2]
 [ 80   3]
 [120   4]]
X.shape   = (3, 2)
X.T =
 [[ 50  80 120]
 [  2   3   4]]
X.T.shape = (2, 3)
```

Nhân ma trận với vector: dự đoán cho nhiều mẫu cùng lúc

Mô hình định giá nhà: *giá* = *0,03* $\times$ *diện tích* + *0,2* $\times$ *số phòng* + *0,5* (tỷ đồng).

Toán dễ hiểu: Nhân ma trận với vector – matrix-vector product

Mỗi phần tử của kết quả = **tích vô hướng một dòng** của ma trận với vector:

$$X\mathbf{w} = \begin{pmatrix} 50 & 2 \\ 80 & 3 \\ 120 & 4 \end{pmatrix} \begin{pmatrix} 0{,}03 \\ 0{,}2 \end{pmatrix} = \begin{pmatrix} 50 \times 0{,}03 + 2 \times 0{,}2 \\ 80 \times 0{,}03 + 3 \times 0{,}2 \\ 120 \times 0{,}03 + 4 \times 0{,}2 \end{pmatrix}$$

Nhân ma trận với vector: dự đoán cho nhiều mẫu cùng lúc

Mô hình định giá nhà: *giá* = *0,03* $\times$ *diện tích* + *0,2* $\times$ *số phòng* + *0,5* (tỷ đồng).

Toán dễ hiểu: Nhân ma trận với vector – matrix-vector product

Mỗi phần tử của kết quả = **tích vô hướng một dòng** của ma trận với vector:

$$X\mathbf{w} = \begin{pmatrix} 50 & 2 \\ 80 & 3 \\ 120 & 4 \end{pmatrix} \begin{pmatrix} 0{,}03 \\ 0{,}2 \end{pmatrix} = \begin{pmatrix} 50 \times 0{,}03 + 2 \times 0{,}2 \\ 80 \times 0{,}03 + 3 \times 0{,}2 \\ 120 \times 0{,}03 + 4 \times 0{,}2 \end{pmatrix} = \begin{pmatrix} 1{,}9 \\ 3{,}0 \\ 4{,}4 \end{pmatrix} \xrightarrow{+0{,}5} \begin{pmatrix} 2{,}4 \\ 3{,}5 \\ 4{,}9 \end{pmatrix}$$

Nhân ma trận với vector: dự đoán cho nhiều mẫu cùng lúc

Mô hình định giá nhà: *giá* = *0,03* $\times$ *diện tích* + *0,2* $\times$ *số phòng* + *0,5* (tỷ đồng).

Toán dễ hiểu: Nhân ma trận với vector – matrix-vector product

Mỗi phần tử của kết quả = **tích vô hướng một dòng** của ma trận với vector:

$$X\mathbf{w} = \begin{pmatrix} 50 & 2 \\ 80 & 3 \\ 120 & 4 \end{pmatrix} \begin{pmatrix} 0{,}03 \\ 0{,}2 \end{pmatrix} = \begin{pmatrix} 50 \times 0{,}03 + 2 \times 0{,}2 \\ 80 \times 0{,}03 + 3 \times 0{,}2 \\ 120 \times 0{,}03 + 4 \times 0{,}2 \end{pmatrix} = \begin{pmatrix} 1{,}9 \\ 3{,}0 \\ 4{,}4 \end{pmatrix} \xrightarrow{+0{,}5} \begin{pmatrix} 2{,}4 \\ 3{,}5 \\ 4{,}9 \end{pmatrix}$$

Lưu ý

Ma trận $n \times d$ nhân vector d phần tử $\Rightarrow$ vector n phần tử. Trong NumPy: `X @ w`. `X * w` là nhân *từng phần tử* – khác hẳn!

Bài tập mẫu: điểm tổng kết bằng phép nhân ma trận

Ví dụ đời thường: Phòng đào tạo tính điểm cho cả trường

Mọi sinh viên dùng cùng công thức 10% chuyên cần, 30% giữa kỳ, 60% cuối kỳ: áp vector trọng số $(0{,}1;\ 0{,}3;\ 0{,}6)$ lên cả bảng điểm.

Bài tập mẫu: Mỗi dòng · vector trọng số

SV1 $(10, 6, 7)$: $1 + 1{,}8 + 4{,}2 = 7{,}0$
SV2 $(8, 9, 8)$: $0{,}8 + 2{,}7 + 4{,}8 = 8{,}3$
SV3 $(9, 5, 4)$: $0{,}9 + 1{,}5 + 2{,}4 = 4{,}8$
SV4 $(7, 8, 9{,}5)$: $0{,}7 + 2{,}4 + 5{,}7 = 8{,}8$

ch03.py — ô mat_diem_tong_ket

```
1  # Điểm (chuyên cần, giữa kỳ, cuối kỳ) của 4 sinh viên
2  diem = np.array([[10, 6, 7],
3                   [8, 9, 8],
4                   [9, 5, 4],
5                   [7, 8, 9.5]])
6  trong_so = np.array([0.1, 0.3, 0.6])      # tỉ trọng 10% - 30% - 60%
7  tong_ket = diem @ trong_so
8  print("Điểm tổng kết:", tong_ket)
9  print("Sinh viên dưới 5:", np.where(tong_ket < 5)[0])
```

Kết quả

```
Điểm tổng kết: [7.  8.3 4.8 8.8]
Sinh viên dưới 5: [2]
```

`np.where`: **vị trí** thỏa điều kiện – sinh viên thứ ba dưới 5.

Kiểm tra bằng NumPy và nhân hai ma trận (*matrix multiplication*)

ch03.py — ô mat_nhan_vector

```
w = np.array([0.03, 0.2])        # trọng số: 0,03 tỷ/m², 0,2 tỷ/phòng ngủ
b = 0.5                          # giá "nền" 0,5 tỷ
gia_du_doan = X @ w + b          # dự đoán cho cả 3 căn trong một phép tính
print("X @ w     =", X @ w)
print("X @ w + b =", gia_du_doan)
```

Kết quả

```
X @ w     = [1.9 3.  4.4]
X @ w + b = [2.4 3.5 4.9]
```

Mẹo nhỏ

C_{ij} = dòng i của A · cột j của B. "Hai số giữa bằng nhau, hai số ngoài là kích thước kết quả": $(3 \times \underline{2}) \cdot (\underline{2} \times 3) \to (3 \times 3)$. Lỗi `matmul ... mismatch`? In `shape` hai ma trận.

$A\ (3 \times 2)$ $\quad$ $B\ (2 \times 3)$ $\quad$ $C\ (3 \times 3)$



$$C_{23} = 3 \times 2 + 4 \times 1 = 10$$

ch03.py — ô mat_nhan_mat

```
A = np.array([[1, 2],
              [3, 4],
              [5, 6]])           # 3 x 2
B = np.array([[1, 0, 2],
              [0, 1, 1]])        # 2 x 3
C = A @ B                        # (3 x 2) @ (2 x 3) -> 3 x 3
print("C =\n", C)
print("C.shape =", C.shape)
```

Bài tập mẫu: kích thước của tích ma trận

A cỡ 4×3, B cỡ 3×2, **v** có 3 phần tử, **u** có 4 phần tử. Phép nào thực hiện được?

Phép
AB
BA
$A\mathbf{v}$
$A\mathbf{u}$
$A^{\top}\mathbf{u}$

Bài tập mẫu: kích thước của tích ma trận

A cỡ 4×3, B cỡ 3×2, **v** có 3 phần tử, **u** có 4 phần tử. Phép nào thực hiện được?

Phép	Được?	Kết quả / lý do
AB	có	$(4 \times \underline{3})(\underline{3} \times 2) \to 4 \times 2$
BA	**không**	$(3 \times \underline{2})(\underline{4} \times 3)$: $2 \neq 4$ – không đổi chỗ được!
$A\mathbf{v}$	có	vector 4 phần tử
$A\mathbf{u}$	**không**	A có 3 cột, **u** có 4 phần tử
$A^\top\mathbf{u}$	có	$A^\top$ cỡ $3 \times 4 \to$ vector 3 phần tử

Mẹo nhỏ

“Hai số ở giữa phải bằng nhau, hai số ở ngoài là kích thước kết quả.”

Phần 3

Thống kê mô tả

Ví dụ đời thường: giới thiệu một lớp học bằng ba câu

Ví dụ đời thường: Thống kê mô tả = nói ba câu bằng con số

Mô tả điểm thi của lớp 50 người chỉ bằng vài câu:

- "Điểm **thường** khoảng 7" ⇒ **xu hướng trung tâm** (*central tendency*).
- "Hầu hết trong khoảng 6 đến 8" ⇒ **độ phân tán** (*dispersion*).
- "Có một bạn 0 điểm vì bỏ thi" ⇒ **giá trị ngoại lai** (*outlier*).

Đây chính là những con số mà `df.describe()` in ra ở Chương 2.

Trung bình, trung vị, yếu vị

Toán dễ hiểu: Xu hướng trung tâm – central tendency

- **Trung bình** (*mean*): $\bar{x} = \frac{1}{n}\sum x_i$ (“x gạch”)
- **Trung vị** (*median*): giá trị đứng giữa khi sắp xếp (n chẵn: trung bình hai giá trị giữa)
- **Yếu vị** (*mode*): giá trị xuất hiện nhiều nhất

Điểm $5, 7, 7, 8, 10$: $\bar{x} = 37/5 = 7{,}4$; trung vị $= 7$; yếu vị $= 7$.

ch03.py — ô tk_trung_tam

```
1 diem = np.array([5, 7, 7, 8, 10])
2 print("Trung bình :", diem.mean())
3 print("Trung vị   :", np.median(diem))
4 gia_tri, so_lan = np.unique(diem,
    ↪ return_counts=True)
5 print("Yếu vị     :",
    ↪ gia_tri[np.argmax(so_lan)])
```

Kết quả

```
Trung bình : 7.4
Trung vị   : 7.0
Yếu vị     : 7
```

Đây là những con số mà `df.describe()` ở Chương 2 đã in ra.

Trung bình hay trung vị?

Lương tháng (triệu đồng) của 7 người trong một công ty nhỏ, trong đó có giám đốc lương 100 triệu:

ch03.py — ô tk_ngoai_lai

```
luong = np.array([8, 9, 10, 10, 11, 12, 100])     # triệu đồng/tháng; có 1 giám đốc
print("Trung bình:", round(luong.mean(), 2), "   Trung vị:", np.median(luong))
```

Kết quả

```
Trung bình: 22.86    Trung vị: 10.0
```

- Trung bình 22,86 triệu **không phản ánh** mức lương của ai cả.
- Trung vị 10 triệu mô tả "người điển hình" tốt hơn nhiều.
- Trung bình rất **nhạy** với **ngoại lai** (*outlier*); trung vị **bền vững** (*robust*).

Mẹo nhỏ

Dữ liệu có ngoại lai hoặc **lệch** (*skewed*) $\Rightarrow$ ưu tiên **trung vị**.

Bài tập mẫu: giá nhà – trung bình hay trung vị?

Giá (tỷ đồng) 6 căn nhà bán trong tháng ở một phường: 2,1; 2,4; 2,5; 2,8; 3,0; **15,0** (biệt thự).

Bài tập mẫu

Lời giải.

- Trung bình $= 27{,}8/6 \approx$ **4,63** tỷ – bị căn biệt thự kéo lên.
- Trung vị: 6 số (chẵn) $\Rightarrow (2{,}5 + 2{,}8)/2 =$ **2,65** tỷ.
- 5 trong 6 căn dưới 3 tỷ $\Rightarrow$ trung vị phản ánh "giá thường gặp" tốt hơn.

Vì vậy các báo cáo về thu nhập, giá nhà thường dùng **trung vị**.

Cùng trung bình, khác độ phân tán

ch03.py — ô tk_hai_lop

```
lop_A = np.array([6, 7, 7, 7, 8])
lop_B = np.array([2, 5, 8, 10, 10])
for ten, lop in [("Lớp A", lop_A), ("Lớp B", lop_B)]:
    print(f"{ten}: trung bình = {lop.mean():.1f}, độ lệch chuẩn = {lop.std():.3f}, "
          f"thấp nhất = {lop.min()}, cao nhất = {lop.max()}")
```

Kết quả

```
Lớp A: trung bình = 7.0, độ lệch chuẩn = 0.632, thấp nhất = 6, cao nhất = 8
Lớp B: trung bình = 7.0, độ lệch chuẩn = 3.098, thấp nhất = 2, cao nhất = 10
```

- Cùng trung bình 7, nhưng độ lệch chuẩn lớp B (3,1) gấp gần 5 lần lớp A (0,63).
- Chỉ nhìn trung bình: hai lớp như nhau. Nhìn thêm độ lệch chuẩn: lớp B có nhiều bạn cần hỗ trợ.
- Công thức tiếp theo cho biết con số độ lệch chuẩn được tính thế nào.

Phương sai và độ lệch chuẩn

Toán dễ hiểu: Độ phân tán – dispersion: phương sai (*variance*), độ lệch chuẩn (*standard deviation*)

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2, \qquad \sigma = \sqrt{\sigma^2} \quad \text{(cùng đơn vị với dữ liệu)}$$

x_i	5	7	7	8	10	Tổng

Phương sai và độ lệch chuẩn

Toán dễ hiểu: Độ phân tán – dispersion: phương sai (*variance*), độ lệch chuẩn (*standard deviation*)

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2, \qquad \sigma = \sqrt{\sigma^2} \quad \text{(cùng đơn vị với dữ liệu)}$$

x_i	5	7	7	8	10	Tổng
$x_i - \bar{x}$	$-2{,}4$	$-0{,}4$	$-0{,}4$	$0{,}6$	$2{,}6$	**0**

Phương sai và độ lệch chuẩn

Toán dễ hiểu: Độ phân tán – dispersion: phương sai (*variance*), độ lệch chuẩn (*standard deviation*)

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2, \qquad \sigma = \sqrt{\sigma^2} \quad \text{(cùng đơn vị với dữ liệu)}$$

x_i	5	7	7	8	10	Tổng
$x_i - \bar{x}$	$-2{,}4$	$-0{,}4$	$-0{,}4$	$0{,}6$	$2{,}6$	**0**
$(x_i - \bar{x})^2$	5,76	0,16	0,16	0,36	6,76	13,2

Phương sai và độ lệch chuẩn

Toán dễ hiểu: Độ phân tán – dispersion: phương sai (*variance*), độ lệch chuẩn (*standard deviation*)

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2, \qquad \sigma = \sqrt{\sigma^2} \quad \text{(cùng đơn vị với dữ liệu)}$$

x_i	5	7	7	8	10	Tổng
$x_i - \bar{x}$	$-2{,}4$	$-0{,}4$	$-0{,}4$	$0{,}6$	$2{,}6$	**0**
$(x_i - \bar{x})^2$	5,76	0,16	0,16	0,36	6,76	13,2

$\sigma^2 = 13{,}2/5 = 2{,}64; \quad \sigma = \sqrt{2{,}64} \approx 1{,}6248.$

Vì sao bình phương? Tổng các độ lệch luôn bằng 0 – phần âm và dương triệt tiêu nhau. Đọc σ: "trung bình, các giá trị lệch khỏi trung bình khoảng σ".

Chia n hay chia $n-1$?

ch03.py — ô tk_phan_tan

```
diem = np.array([5, 7, 7, 8, 10])
print("Phương sai (chia n)      :", round(diem.var(), 4))
print("Độ lệch chuẩn (chia n)   :", round(diem.std(), 4))
print("Độ lệch chuẩn (chia n-1) :", round(diem.std(ddof=1), 4))
print("pandas .std() mặc định   :", round(pd.Series(diem).std(), 4))
```

Kết quả

```
Phương sai (chia n)      : 2.64
Độ lệch chuẩn (chia n)   : 1.6248
Độ lệch chuẩn (chia n-1) : 1.8166
pandas .std() mặc định   : 1.8166
```

Lưu ý

NumPy mặc định chia n (phương sai *tổng thể*, *population*), pandas mặc định chia $n-1$ (phương sai *mẫu*, *sample*) $\Rightarrow$ `np.std` và `df.std()` hơi khác nhau. `ddof=1` chuyển NumPy sang chia $n-1$. Dữ liệu lớn: khác biệt không đáng kể.

Phân vị và quy tắc 1,5 IQR

Toán dễ hiểu: Tứ phân vị – quartiles

- **Phân vị** (*percentile*) $p\%$: giá trị mà khoảng $p\%$ dữ liệu nhỏ hơn nó.
- Q_1, Q_2 (trung vị), Q_3: phân vị 25%, 50%, 75%.
- **Khoảng tứ phân vị** (*IQR, interquartile range*) $= Q_3 - Q_1$: độ rộng "nửa giữa" = chiều cao hộp trong boxplot.

Ngoại lai nếu nằm ngoài

$$[\,Q_1 - 1{,}5\,\text{IQR},\ Q_3 + 1{,}5\,\text{IQR}\,]$$

ch03.py — ô tk_phan_vi

```
du_lieu = np.array([2, 4, 4, 5, 6, 7, 8, 9, 12, 30])
q1, q2, q3 = np.percentile(du_lieu, [25, 50, 75])
iqr = q3 - q1
print("Q1 =", q1, " Q2 (trung vị) =", q2, " Q3 =", q3, " IQR =", iqr)
can_duoi, can_tren = q1 - 1.5 * iqr, q3 + 1.5 * iqr
print("Khoảng bình thường: [", can_duoi, ",", can_tren, "]")
print("Giá trị ngoại lai :", du_lieu[(du_lieu < can_duoi) | (du_lieu > can_tren)])
```

Kết quả

```
Q1 = 4.25  Q2 (trung vị) = 6.5  Q3 = 8.75  IQR = 4.5
Khoảng bình thường: [ -2.5 , 15.5 ]
Giá trị ngoại lai : [30]
```

Giá trị 30 bị phát hiện. NumPy *nội suy* giữa hai giá trị liền kề, nên $Q_1 = 4{,}25$ dù dữ liệu không có số này.

Bài tập mẫu: tính tay tứ phân vị (cách của NumPy)

Dữ liệu (đã sắp xếp, $n = 10$, vị trí 0–9): 2, 4, **4**, **5**, 6, 7, **8**, **9**, 12, 30.

Bài tập mẫu: Phân vị $p\%$ nằm ở vị trí $(n-1) \times p/100$

Lời giải.

- Q_1: vị trí $9 \times 0{,}25 = 2{,}25$ – giữa 4 (vị trí 2) và 5 (vị trí 3): $Q_1 = 4 + 0{,}25 \times 1 = 4{,}25$.
- Q_3: vị trí $9 \times 0{,}75 = 6{,}75$ – giữa 8 và 9: $Q_3 = 8 + 0{,}75 \times 1 = 8{,}75$.
- IQR $= 4{,}5$; ngưỡng trên $8{,}75 + 6{,}75 = 15{,}5$; ngưỡng dưới $4{,}25 - 6{,}75 = -2{,}5 \Rightarrow$ 30 là ngoại lai.

Có nhiều quy ước tính phân vị (sách phổ thông có thể khác chút); với dữ liệu lớn, các cách cho kết quả gần như nhau.

Hệ số tương quan Pearson (*Pearson correlation coefficient*)

Toán dễ hiểu: Hai biến cùng tăng cùng giảm theo đường thẳng đến đâu?

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2}\,\sqrt{\sum (y_i - \bar{y})^2}}, \qquad -1 \le r \le 1$$

Giờ học $x = (2, 4, 6, 8, 10)$, điểm thi $y = (4, 5, 7, 8, 9)$; $\bar{x} = 6$, $\bar{y} = 6{,}6$.

$x_i - \bar{x}$	-4	-2	0	2	4
$y_i - \bar{y}$	$-2{,}6$	$-1{,}6$	$0{,}4$	$1{,}4$	$2{,}4$

Hệ số tương quan Pearson (*Pearson correlation coefficient*)

Toán dễ hiểu: Hai biến cùng tăng cùng giảm theo đường thẳng đến đâu?

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2}\,\sqrt{\sum (y_i - \bar{y})^2}}, \qquad -1 \le r \le 1$$

Giờ học $x = (2, 4, 6, 8, 10)$, điểm thi $y = (4, 5, 7, 8, 9)$; $\bar{x} = 6$, $\bar{y} = 6{,}6$.

$x_i - \bar{x}$	-4	-2	0	2	4	
$y_i - \bar{y}$	$-2{,}6$	$-1{,}6$	$0{,}4$	$1{,}4$	$2{,}4$	
Tích	10,4	3,2	0	2,8	9,6	$\sum = 26$

Hệ số tương quan Pearson (*Pearson correlation coefficient*)

Toán dễ hiểu: Hai biến cùng tăng cùng giảm theo đường thẳng đến đâu?

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2}\,\sqrt{\sum (y_i - \bar{y})^2}}, \qquad -1 \le r \le 1$$

Giờ học $x = (2, 4, 6, 8, 10)$, điểm thi $y = (4, 5, 7, 8, 9)$; $\bar{x} = 6$, $\bar{y} = 6{,}6$.

$x_i - \bar{x}$	-4	-2	0	2	4	
$y_i - \bar{y}$	$-2{,}6$	$-1{,}6$	$0{,}4$	$1{,}4$	$2{,}4$	
Tích	10,4	3,2	0	2,8	9,6	$\sum = 26$
$(x_i - \bar{x})^2$	16	4	0	4	16	$\sum = 40$
$(y_i - \bar{y})^2$	6,76	2,56	0,16	1,96	5,76	$\sum = 17{,}2$

Hệ số tương quan Pearson (*Pearson correlation coefficient*)

Toán dễ hiểu: Hai biến cùng tăng cùng giảm theo đường thẳng đến đâu?

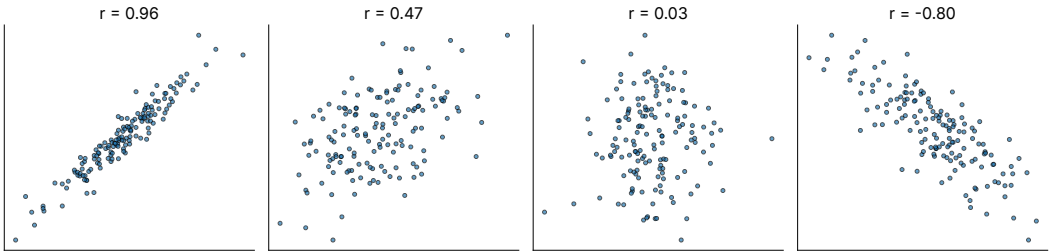
$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2}\,\sqrt{\sum (y_i - \bar{y})^2}}, \qquad -1 \le r \le 1$$

Giờ học $x = (2, 4, 6, 8, 10)$, điểm thi $y = (4, 5, 7, 8, 9)$; $\bar{x} = 6$, $\bar{y} = 6{,}6$.

$x_i - \bar{x}$	-4	-2	0	2	4	
$y_i - \bar{y}$	$-2{,}6$	$-1{,}6$	$0{,}4$	$1{,}4$	$2{,}4$	
Tích	10,4	3,2	0	2,8	9,6	$\sum = 26$
$(x_i - \bar{x})^2$	16	4	0	4	16	$\sum = 40$
$(y_i - \bar{y})^2$	6,76	2,56	0,16	1,96	5,76	$\sum = 17{,}2$

$$r = \frac{26}{\sqrt{40} \times \sqrt{17{,}2}} = \frac{26}{6{,}3246 \times 4{,}1473} \approx \mathbf{0{,}9912}$$ (`np.corrcoef` cho cùng kết quả)

Đọc hệ số tương quan



- $r \approx +1$: **tương quan thuận** (*positive correlation*) mạnh; $r \approx -1$: **nghịch** (*negative*) mạnh.
- $r \approx 0$: không có quan hệ *tuyến tính* (vẫn có thể có quan hệ đường cong).
- $|r| > 0{,}7$ mạnh; $0{,}3$–$0{,}7$ trung bình; $< 0{,}3$ yếu.

Lưu ý

Tương quan $\neq$ nhân quả (*correlation is not causation*). Kem bán ra và số vụ đuối nước cùng tăng – vì cùng vào mùa hè, không phải ăn kem gây đuối nước.

Tương quan âm và một cái bẫy: $r = 0$

ch03.py — ô tk_tuong_quan_am

```
gio_choi_game = np.array([1, 2, 3, 4, 5])
diem_thi = np.array([9, 8, 8, 6, 4])
print("r(giờ chơi game, điểm) =", round(np.corrcoef(gio_choi_game, diem_thi)[0, 1], 4))
x = np.array([-2, -1, 0, 1, 2])
y = x ** 2                                  # quan hệ hoàn hảo nhưng là đường cong
print("r(x, x²) =", round(np.corrcoef(x, y)[0, 1], 4))
```

Kết quả

```
r(giờ chơi game, điểm) = -0.9487
r(x, x²) = 0.0
```

- Giờ chơi game càng nhiều, điểm càng thấp: $r \approx -0{,}95$ – **tương quan nghịch** (*negative correlation*) rất mạnh.
- $y = x^2$ là quan hệ **hoàn hảo** nhưng $r = 0$: đường parabol, nửa trái đi xuống, nửa phải đi lên, triệt tiêu nhau.
- r chỉ đo quan hệ **tuyến tính** (*linear*).

Tự kiểm tra nhanh: thống kê mô tả

1. Dãy $1, 2, 3, 4, 100$: trung bình và trung vị? Số nào mô tả dữ liệu tốt hơn?
2. Dãy $5, 5, 5, 5$ có độ lệch chuẩn bằng bao nhiêu? Vì sao?
3. $r = 0$ có nghĩa là hai biến hoàn toàn không liên quan không?

Tự kiểm tra nhanh: thống kê mô tả

1. Dãy $1, 2, 3, 4, 100$: trung bình và trung vị? Số nào mô tả dữ liệu tốt hơn?
2. Dãy $5, 5, 5, 5$ có độ lệch chuẩn bằng bao nhiêu? Vì sao?
3. $r = 0$ có nghĩa là hai biến hoàn toàn không liên quan không?

Đáp án

(1) 22 và 3; trung vị tốt hơn (100 là ngoại lai). (2) 0 – không có độ lệch nào. (3) Không – chỉ là không có quan hệ **tuyến tính**.

Phần 4

Thực hành Buổi 3.1

Thực hành 3.1: Toán trên dữ liệu Iris

Bước 1. Trung bình, độ lệch chuẩn từng đặc trưng (`axis=0`).

ch03.py — ô lab_buoc1

```
from sklearn.datasets import load_iris
iris = load_iris(as_frame=True)
X = iris.data.to_numpy()                  # mảng NumPy 150 x 4
y = iris.target.to_numpy()
print("Trung bình từng đặc trưng :", X.mean(axis=0).round(3))
print("Độ lệch chuẩn từng đặc trưng:", X.std(axis=0).round(3))
```

Kết quả

```
Trung bình từng đặc trưng : [5.843 3.057 3.758 1.199]
Độ lệch chuẩn từng đặc trưng: [0.825 0.434 1.759 0.76 ]
```

Chiều dài cánh hoa có độ lệch chuẩn lớn nhất (1,759): thay đổi nhiều nhất giữa các bông hoa.

Thực hành 3.1: Tự tìm hàng xóm gần nhất

Bước 2. Bông hoa mới $(5{,}9;\ 3{,}0;\ 4{,}9;\ 1{,}7)$: khoảng cách tới 150 bông, lấy 5 bông gần nhất.

ch03.py — ô lab_buoc2

```
hoa_moi = np.array([5.9, 3.0, 4.9, 1.7])
khoang_cach = np.sqrt(((X - hoa_moi) ** 2).sum(axis=1))   # 150 khoảng cách
gan_nhat = np.argsort(khoang_cach)[:5]                    # vị trí 5 bông gần nhất
for i in gan_nhat:
    print(f"Bông số {i:3d}: khoảng cách = {khoang_cach[i]:.4f}, "
          f"loài = {iris.target_names[y[i]]}")
```

Kết quả

```
Bông số 138: khoảng cách = 0.1732, loài = virginica
Bông số 127: khoảng cách = 0.2236, loài = virginica
Bông số 149: khoảng cách = 0.2236, loài = virginica
Bông số  70: khoảng cách = 0.2449, loài = versicolor
Bông số  83: khoảng cách = 0.3873, loài = versicolor
```

- Dòng 2: **broadcasting** trừ vector khỏi mọi dòng; `.sum(axis=1)`: mỗi dòng một khoảng cách.
- 3 *virginica*, 2 *versicolor* $\Rightarrow$ kNN ($k = 5$) dự đoán **virginica**; bông hoa nằm ở vùng ranh giới.

Thực hành 3.1: Ma trận tương quan

Bước 3. Tương quan giữa bốn đặc trưng.

ch03.py — ô lab_buoc3

```
tq = iris.data.corr().round(3)
tq.columns = ["dai_dai", "rong_dai", "dai_canh", "rong_canh"]
tq.index = tq.columns
print(tq)
```

Kết quả

```
            dai_dai  rong_dai  dai_canh  rong_canh
dai_dai       1.000    -0.118     0.872      0.818
rong_dai     -0.118     1.000    -0.428     -0.366
dai_canh      0.872    -0.428     1.000      0.963
rong_canh     0.818    -0.366     0.963      1.000
```

- Dài và rộng cánh hoa: $r = 0{,}963$ – gần như "nói cùng một điều".
- Rộng đài hoa tương quan nghịch, mức yếu đến trung bình, với các đặc trưng còn lại.

Bảng thuật ngữ Việt – Anh của buổi học

Tiếng Việt	Tiếng Anh
Vector	Vector
Số chiều	Dimension
Độ dài (chuẩn)	Norm
Khoảng cách Euclid	Euclidean distance
Thang đo	Scale
Tích vô hướng	Dot product
Độ tương đồng cosine	Cosine similarity
Ma trận	Matrix
Ma trận chuyển vị	Transpose

Tiếng Việt	Tiếng Anh
Nhân ma trận	Matrix multiplication
Trung bình	Mean
Trung vị	Median
Yếu vị	Mode
Phương sai	Variance
Độ lệch chuẩn	Standard deviation
Tứ phân vị	Quartile
Khoảng tứ phân vị	Interquartile range (IQR)
Hệ số tương quan	Correlation coefficient

Phần 5

Tổng kết Buổi 3.1

Tóm tắt Buổi 3.1

- Mỗi mẫu dữ liệu là một **vector**; cả bộ dữ liệu là một **ma trận** $n \times d$.
- **Khoảng cách Euclid** $\sqrt{\sum_j (p_j - q_j)^2}$ đo độ giống nhau; đổi đơn vị một cột có thể đảo ngược kết luận.
- **Tích vô hướng w · x** $= \sum_j w_j x_j$; `X @ w` tính cho mọi mẫu cùng lúc. Cosine đo độ giống về hướng.
- Trung bình nhạy với ngoại lai, trung vị thì không; độ lệch chuẩn đo độ phân tán; quy tắc 1,5 IQR phát hiện ngoại lai.
- Hệ số tương quan r đo quan hệ **tuyến tính**, không chứng minh nhân quả.

Câu hỏi thảo luận

1. Vì sao có thể nói “mỗi mẫu dữ liệu là một vector”? Cho ví dụ với một bộ dữ liệu bạn tự nghĩ ra.
2. Tích vô hướng là một số hay một vector? Nêu một ví dụ đời thường.
3. Ma trận 5×3 nhân được với ma trận nào trong các ma trận cỡ 3×2, 5×3, 3×5? Kết quả cỡ bao nhiêu?
4. Khi nào nên dùng trung vị thay cho trung bình?
5. $r = -0{,}85$ nghĩa là gì? Có kết luận được biến này gây ra biến kia không?

Bài tập Buổi 3.1

- ⋆ **3.1**: $\mathbf{a} = (2, -1, 3)$, $\mathbf{b} = (1, 4, 0)$: tính tay $\mathbf{a} + \mathbf{b}$, $3\mathbf{a} - \mathbf{b}$, $\|\mathbf{a}\|$, $\mathbf{a} \cdot \mathbf{b}$, khoảng cách; kiểm tra bằng NumPy.
- ⋆ **3.2**: Đơn giá $(20, 35, 50)$; ba khách mua $(1, 2, 0)$, $(0, 1, 3)$, $(4, 0, 1)$: số tiền mỗi khách bằng **một** phép nhân.
- ⋆ **3.3**: Trung bình, trung vị, phương sai, độ lệch chuẩn của $3, 6, 6, 7, 8, 12$.
- ⋆ **3.4**: P $= (160, 8)$, Q $= (161, 4)$, R $= (170, 8)$ (chiều cao, điểm toán): P giống ai hơn? Có hợp lý không?
- ⋆⋆ **3.5**: tips: đếm hóa đơn `total_bill` ngoại lai theo quy tắc 1,5 IQR; vẽ boxplot kiểm tra.
- ⋆⋆ **3.6**: Tính tay r giữa $x = (1, 2, 3, 4)$ và $y = (10, 8, 5, 1)$; kiểm tra bằng `np.corrcoef`.

Chi tiết: *Bài tập Buổi 3.1*, Chương 3. Buổi sau: **Buổi 3.2 – Đạo hàm, gradient descent và xác suất**.